

PHÂN HIỆU TRƯỜNG ĐẠI HỌC THỦY LỢI
BỘ MÔN CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN: KHAI PHÁ DỮ LIỆU

Tên đề tài: Leaf Disease Classification

Giảng viên hướng dẫn:	<i>ThS. Vũ Thị Hạnh</i>
Lớp: S25-64CNTT	Thành viên
Nhóm thực hiện:	Nguyễn Đình Phước Cao - 225106 Nguyễn Thành Thịnh - 2251068257 Nguyễn Phùng Thịnh - 2251068256

HCM, tháng 10 năm 2025

Lời cảm ơn

Nhóm em xin chân thành cảm ơn các thầy cô giáo Phân Hiệu Trường Đại Học Thủy Lợi và đặc biệt là các thầy cô giáo Bộ môn Công nghệ thông tin đã dạy cho nhóm có được những kiến thức cơ bản vững chắc để phục vụ cho việc hoàn thành bài tập lớn này. Đặc biệt, trong thời gian làm bài tập lớn chúng em đã được sự giảng dạy của ThS. Vũ Thị Hạnh, đã cho chúng em các kiến thức về khai phá dữ liệu. Xin chân thành cảm ơn về những kiến thức mà các cô đã dành cho chúng em, bổ sung cho chúng em những kiến thức cơ bản, cho chúng em những lời khuyên, sự góp ý để chúng em có thể hoàn thành bài tập lớn và bước đầu xây dựng được hoàn chỉnh của nhóm một cách nhanh chóng và hiệu quả nhất. Trong quá trình làm bài tập lớn chúng em đã cố gắng hết sức để hoàn thiện một cách tốt nhất. Nhưng do kiến thức còn hạn chế, thời gian làm bài tập lớn có hạn và kinh nghiệm thực tế chưa nhiều nên chúng em không thể tránh được những sai sót. Vì thế chúng em rất mong nhận được sự góp ý của thầy và các bạn để bài tập lớn của em trở nên hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

MỤC LỤC

1. Giới thiệu đề tài.....	4
2. Mục tiêu và bài toán đặt ra.....	5
Mục tiêu chính: Xây dựng hệ thống phân loại bệnh trên lá cây tự động, có độ chính xác cao, giúp nông dân và nhà nghiên cứu phát hiện sớm bệnh thực vật.....	5
Bài toán cụ thể	5
3. Mô tả dữ liệu và các bước tiền xử lý.....	6
3.1. Tổng quan về tập dữ liệu:.....	6
3.2. Các bước tiền xử lý	8
4. Phương pháp khai phá dữ liệu / Mô hình ML.....	9
4.1. Tổng quan.....	9
4.2. Các mô hình sử dụng.....	9
4.3. Cấu hình huấn luyện.....	9
4.4. Quy trình huấn luyện.....	9
4.5. Trực quan hóa kết quả huấn luyện.....	10
4.6. So sánh mô hình.....	10
5. Kết quả và đánh giá mô hình (độ chính xác, biểu đồ, confusion matrix, giao diện trên web).....	11
5.1. Độ chính xác và hội tụ huấn luyện.....	11
5.2. Ma trận nhầm lẫn (Confusion Matrix).....	12
5.3. F1-Score theo lớp.....	14
5.4. Precision – Recall Relationship.....	15
5.5. Phân tích Top Easy / Hard Classes.....	17
5.6. Tổng hợp & So sánh mô hình.....	18
5.7. Kết luận phân đánh giá	18
6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN:.....	19
6.1. Kết luận:.....	19
6.2. Những đóng góp chính của đề tài.....	19
6.3. Hạn chế.....	19
6.4. Hướng phát triển tiếp theo.....	19
6.5. Kết luận cuối cùng.....	20
7. Tài liệu tham khảo.....	21

BÁO CÁO CHI TIẾT – KHAI PHÁ DỮ LIỆU ẢNH BỆNH LÁ CÂY

1. Giới thiệu đề tài:

Đề tài tập trung vào xây dựng mô hình học sâu để phân loại bệnh lá cây dựa trên ảnh chụp. Dữ liệu lấy bộ New Plant Diseases Dataset (Augmented), đã tách sẵn train/valid theo thư mục. bao gồm các ảnh được tổ chức theo 38 lớp (mỗi lớp đại diện cho một loại bệnh hoặc trạng thái khỏe).

2. Mục tiêu và bài toán đặt ra

Mục tiêu chính: Xây dựng hệ thống phân loại bệnh trên lá cây tự động, có độ chính xác cao, giúp nông dân và nhà nghiên cứu phát hiện sớm bệnh thực vật.

Bài toán cụ thể:

1. Tiền xử lý dữ liệu ảnh thống nhất kích thước, đưa về dạng Tensor và chuẩn hóa theo ImageNet.
2. Kiểm tra và giải quyết mất cân bằng lớp bằng trọng số.
3. Xây dựng một mô hình
4. Áp dụng early stopping để tránh overfitting và lưu model tốt nhất.
5. Đánh giá hiệu suất qua learning curves, confusion matrix và minh họa trực quan.

3. Mô tả dữ liệu và các bước tiền xử lý

3.1. Tổng quan về tập dữ liệu:

Có tổng cộng khoảng 87.900 hình ảnh lá cây, với kích thước đã được thiết lập là: 256x256.



Dữ liệu được tổ chức theo 38 lớp, mỗi lớp đại diện cho một loại cây trồng cụ thể có kết hợp với tình trạng của cây.


Có 14 loại cây trồng chính: Apple (táo), Blueberry (việt quất), Cherry (anh đào), Corn (ngô), Grape (nho), Orange (cam), Peach (đào), Pepper (ớt), Potato (khoai tây), Raspberry (mâm xôi), Soybean (đậu nành), Squash (bí đỏ), Strawberry (dâu tây), Tomato (cà chua).

Có các tình trạng của loại cây gồm: Healthy và bệnh cụ thể của cây trồng (Scab, Mosaic Virus, Late Blight,...)

Tập train: Dùng để huấn luyện mô hình với 70.295 hình ảnh, 38 lớp (1.06GG).

Tập val và test: Dùng để kiểm tra và xác thực





Kiến thức về sâu bệnh thực vật học:

Các tác nhân gây sâu bệnh chính:

Tác nhân	Mô tả	Ví dụ điển hình	Triệu chứng điển hình
Nấm	Tác nhân phổ biến gây ra bệnh của cây	Potato Late Blight Tomato Early Blight	Xuất hiện đốm có màu nâu/đen trên lá, có mốc trắng, héo úa.
Vì khuẩn	Lan qua nước mưa, các côn trùng, phát triển nhanh ở ẩm ẩm	Citrus Canker Bacterial Spot	Có vết loét ướt và đốm nước xuất hiện trên lá
Virus	Lan qua côn trùng, các dụng cụ cắt/tĩa chưa vệ sinh kỹ. Với tác nhân là virus chỉ có thể phòng ngừa, không chữa được	Tomato Mosaic Virus Peach Mosaic Virus	Xuất hiện đốm vàng trên lá, lá bị xoắn lại, cây bị thấp hơn các cây bình thường.
Sâu bọ	Ăn trực tiếp hoặc truyền bệnh	Aphids (rệp) trên nhiều cây. Caterpillars trên Tomato/Corn.	Xuất hiện lỗ thủng trên lá, mật ngọt gây nấm đen
Nematodes/Khác	Ký sinh rễ; hiếm hơn nhưng phá hoại lâu dài.	R o o t - k n o t nematodes trên Potato/Soybean.	Rễ sưng, cây còi cọc.

3.2. Các bước tiền xử lý

Transform dữ liệu:

- `Resize(224,224)`: đưa ảnh về cùng kích thước.
- `ToTensor()`: chuyển ảnh sang tensor.
- `Normalize(mean, std)`: chuẩn hóa theo tham số ImageNet.

Khử chuẩn hóa: Dùng `inv_transform` để hiển thị ảnh gốc.

Tạo `DataLoader`:

- `batchSize = 32`, `shuffle=True` cho train, `False` cho valid.
- Sử dụng `num_workers=4` để tăng tốc độ.

Kiểm tra mất cân bằng:

- Đếm số mẫu mỗi lớp, tính tỷ lệ max/min.
- Tạo trọng số lớp: lớp hiếm được gán giá trị cao hơn trong hàm mất mát.

Kết quả in ra:

- Số ảnh/lớp, tỷ lệ mất cân bằng, danh sách lớp, trọng số.

4. Phương pháp khai phá dữ liệu / Mô hình ML

4.1. Tổng quan

Phần huấn luyện mô hình được triển khai trong module `model_training.py`, gồm các thành phần chính: định nghĩa mô hình (Model Definition), hàm huấn luyện (Training Function), trực quan hóa (Visualization), so sánh mô hình (Model Comparison), và khối thực thi chính (Main Block). Hệ thống được thiết kế mô-đun hóa, cho phép dễ dàng mở rộng thêm các mô hình mới.

4.2. Các mô hình sử dụng

Module cung cấp 4 mô hình CNN khác nhau để huấn luyện và so sánh:

a. CNN đơn giản (Baseline)

- Cấu trúc gồm 4 tầng tích chập Conv2d + BatchNorm2d + ReLU + MaxPool2d, sau đó là AdaptiveAvgPool2d(1) và Linear(256 → 38).
- Có lớp **Dropout(0.5)** để giảm overfitting.
- Mục tiêu: dùng làm mốc so sánh cho các mô hình pre-trained.

b. ResNet18 (Pretrained)

- Sử dụng `ResNet18_Weights.IMAGENET1K_V1`.
- Thay thế fully-connected layer cuối cùng bằng `nn.Linear(num_fts, num_classes)`.
- Ưu điểm: học sâu và khả năng tổng quát tốt nhờ residual blocks.

c. MobileNetV2 (Pretrained)

- Dùng `MobileNet_V2_Weights.IMAGENET1K_V1`.
- Thay đổi layer cuối: `nn.Linear(num_fts, num_classes)`.
- Ưu điểm: nhẹ, tối ưu cho thiết bị di động, tốc độ nhanh.

d. EfficientNet-B0 (Pretrained)

- Dùng `EfficientNet_B0_Weights.IMAGENET1K_V1`.
- Sửa `model.classifier[1]` thành `nn.Linear(num_fts, num_classes)`.
- Ưu điểm: kiến trúc tối ưu giữa hiệu năng và độ chính xác.

4.3. Cấu hình huấn luyện

- Loss function: `CrossEntropyLoss(weight=class_weights)` – có trọng số lớp để khắc phục mất cân bằng dữ liệu.
- Optimizer: Adam với `lr=0.0001`, có `weight_decay=1e-4`.
- Scheduler: `ReduceLROnPlateau` – giảm learning rate khi validation loss không giảm sau 3 epoch.
- Early Stopping: dừng huấn luyện nếu không cải thiện sau `patience = 5` epoch.
- **Epoch tối đa:** 50 (có thể tăng đến 100 cho kết quả tốt hơn).

4.4. Quy trình huấn luyện

- Training phase: mô hình ở chế độ train, cập nhật trọng số qua backpropagation.
- Validation phase: tính toán loss và accuracy trên tập validation.
- Scheduler step: giảm LR khi cần thiết.
- Lưu mô hình tốt nhất: khi validation loss giảm, model sẽ được lưu vào `models/best_<model_name>.pth`.

- Early stopping: nếu loss không cải thiện, dừng để tránh overfitting.

4.5. Trực quan hóa kết quả huấn luyện

Hàm `plot_learning_curves()` tạo biểu đồ gồm:

- Loss Curve: hiển thị Train/Validation Loss theo từng epoch.
- Accuracy Curve: hiển thị Train/Validation Accuracy. → Hình được lưu tại thư mục `plots/<model_name>_learning_curves.png`.

4.6. So sánh mô hình


Hàm `run_model_comparison()` thực hiện:

- Huấn luyện lần lượt 3 mô hình: ResNet18, MobileNetV2, EfficientNetB0.
- Vẽ biểu đồ Learning Curves cho từng mô hình.
- Ghi lại kết quả best validation accuracy và best validation loss để so sánh.

5. Kết quả và đánh giá mô hình (độ chính xác, biểu đồ, confusion matrix, giao diện trên web):

5.1. Độ chính xác và hội tụ huấn luyện

- Cả ba mô hình ResNet18, MobileNetV2, EfficientNet-B0 đều đạt độ chính xác rất cao trên tập validation (>98%), chứng tỏ pipeline tiền xử lý, cân bằng lớp và augmentation hoạt động tốt.
- Biểu đồ Loss/Accuracy cho thấy mô hình hội tụ nhanh, không có dấu hiệu overfitting.
 - ResNet18: hội tụ sau ~25–30 epochs, Validation Accuracy $\approx 99.3\%$, Loss giảm ổn định.
 - MobileNetV2: hội tụ sớm hơn (~20–22 epochs), Validation Accuracy $\approx 99.2\%$.
 - EfficientNet-B0: đạt độ chính xác cao nhất, hội tụ nhanh (~15 epochs), Val Acc $\approx 99.6\%$.
- Sự chênh lệch nhỏ giữa Train và Valid chứng minh mô hình học tổng quát tốt, không bị lệch dữ liệu.



5.2. Ma trận nhầm lẫn (Confusion Matrix)

ResNet18


- Hầu hết các lớp nằm trên đường chéo chính, chứng tỏ tỷ lệ dự đoán đúng cao.
- Các lớp khác gần như dự đoán hoàn hảo (Apple, Tomato, Grape).



MobileNetV2

- Confusion Matrix của MobileNetV2 cũng rất “sạch”, chỉ xuất hiện vài ô sáng ngoài chéo (ít lỗi).
- Mô hình tỏ ra tốt hơn với nhóm Tomato, một số trường hợp *Tomato__Target_Spot* bị nhầm với *Tomato__Late_blight*.

EfficientNet-B0


- Ma trận nhầm lẫn rất gần như hoàn hảo.
- Gần như không có lỗi phân loại đáng kể, chỉ vài trường hợp mờ nhạt ở nhóm Corn và Grape.
- Thể hiện rõ khả năng tổng quát hóa mạnh và tính ổn định của EfficientNet nhờ scaling hợp lý (depth, width, resolution).






5.3. F1-Score theo lớp


- Biểu đồ F1-Score per class cho thấy các mô hình đều đạt >0.98 trên hầu hết lớp.
- Các lớp “khó” nhất thường là:
 - *Corn (maize) Cercospora Leaf Spot (Gray Leaf Spot)*
 - *Tomato Target Spot / Late Blight / Early Blight*
 - *Peach healthy* hoặc *Blueberry healthy* (vì ảnh “healthy” có độ đa dạng ánh sáng cao).
- Các lớp “dễ” có F1 gần tuyệt đối (≈ 1.00):
 - *Apple Black Rot, Apple Scab, Potato Late Blight, Grape Leaf Blight*, v.v.
- Trung bình toàn bộ 38 lớp:
 - ResNet18: F1 = 0.989
 - MobileNetV2: F1 = 0.991
 - EfficientNet-B0: F1 = 0.996






5.4. Precision – Recall Relationship


- Biểu đồ Precision vs Recall của cả ba mô hình đều nằm sát đường chéo “Perfect”, thể hiện khả năng cân bằng tốt giữa precision và recall.
- EfficientNet-B0 cho phân bố điểm gần như chồng lên đường Perfect line, trong khi ResNet18 và MobileNetV2 có vài điểm lệch nhẹ (<0.01), tương ứng với những lớp bị nhầm nhỏ.



Precision vs Recall - MobileNetV2








Precision vs Recall - ResNet18



5.5. Phân tích Top Easy / Hard Classes

- Top 10 Easy Classes ($F1 \approx 1.00$):
Apple__Black_rot, Grape__healthy, Corn__healthy, Potato__Late_blight, Grape_Esca_(Black_Measles), Tomato_healthy
- Top 10 Hard Classes ($F1 \approx 0.93\text{--}0.97$):
Corn_(maize)__Gray_leaf_spot, Tomato__Target_Spot, Tomato_Bacterial_spot, Peach_healthy
- Kết luận: Những lớp khó thường thuộc nhóm *Tomato* và *Corn* vì ảnh có đặc điểm tương tự (màu, kết cấu lá).





5.6. Tổng hợp & So sánh mô hình:

Mô hình	Val Accuracy	Trung bình F1	Ưu điểm	Hạn chế
ResNet18	99.3%	0.989	Ổn định, dễ huấn luyện	Lâu hội tụ, trọng số lớn
MobileNetV2	99.2%	0.991	Nhẹ, phù hợp triển khai di động	Một số lớp Tomato còn nhầm
EfficientNet-B0	99.6%	0.996	Hiệu quả nhất, cân bằng tốt giữa tốc độ và độ chính xác	Cần GPU để train nhanh

5.7. Kết luận phần đánh giá:

- Mô hình EfficientNet-B0 vượt trội nhất về độ chính xác và khả năng khái quát.
- MobileNetV2 là lựa chọn tối ưu khi cần triển khai thực tế (trên thiết bị giới hạn tài nguyên).
- ResNet18 phù hợp cho nghiên cứu nền tảng hoặc huấn luyện nhanh.
- Hệ thống có thể mở rộng thêm Grad-CAM++ để giải thích vùng chú ý — giúp xác thực mô hình không học “nhiều nền”.

6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN:

6.1. Kết luận:

Qua toàn bộ quá trình nghiên cứu và thực nghiệm, đề tài “Nhận dạng bệnh cây trồng từ ảnh lá ” đã đạt được các kết quả sau:

- Xây dựng thành công pipeline huấn luyện hoàn chỉnh, bao gồm: tiền xử lý dữ liệu (preprocessing), phân tích dữ liệu khám phá (EDA), trích xuất đặc trưng (feature engineering), huấn luyện – so sánh mô hình (model training), và đánh giá (evaluation).
- Áp dụng ba mô hình học sâu phổ biến: ResNet18, MobileNetV2 và EfficientNet-B0, đều đạt độ chính xác cao trên 98%, trong đó EfficientNet-B0 vượt trội với Accuracy 99.6% và F1-Score trung bình 0.996.
- Sử dụng hiệu quả kỹ thuật tăng cường dữ liệu (augmentation), giúp mô hình tránh overfitting và cải thiện khả năng tổng quát hóa trên 38 lớp bệnh.
- Kết quả đánh giá trực quan (Confusion Matrix, F1 per class, Precision–Recall, Easy/Hard Classes) chứng minh rằng mô hình học được đặc trưng đặc trưng phân biệt giữa các bệnh lá cây có hình thái gần giống.
- MobileNetV2 thể hiện ưu thế về kích thước nhỏ và tốc độ nhanh, phù hợp triển khai trên thiết bị di động hoặc edge device.

6.2. Những đóng góp chính của đề tài:

- Tích hợp đầy đủ quy trình Machine Learning thực tiễn, có thể tái sử dụng cho các bài toán tương tự trong nông nghiệp.
- Đánh giá định lượng và định tính toàn diện: Accuracy, F1, Confusion Matrix, Precision–Recall, Top Easy/Hard.
- Phân tích khả năng tổng quát hóa giữa các mô hình, chỉ ra ưu/nhược điểm thực tế khi huấn luyện trên tập dữ liệu nhiều lớp và mất cân bằng.
- Đề xuất giải pháp triển khai thực tế (MobileNetV2 hoặc EfficientNet-B0 giảm kích thước model).

6.3. Hạn chế

Mặc dù mô hình đạt hiệu quả cao, đề tài vẫn còn một số hạn chế:

- Tập dữ liệu chưa bao phủ đầy đủ các điều kiện ánh sáng và góc chụp thực tế, do đó mô hình có thể bị giảm hiệu suất khi gặp ảnh ngoài thực địa.
- Chưa triển khai Grad-CAM++ visualization trực tiếp trong báo cáo, để minh họa vùng chú ý trên lá.
- Chưa thử nghiệm ensemble (kết hợp nhiều mô hình) để cải thiện kết quả hơn nữa.

6.4. Hướng phát triển tiếp theo

Trong tương lai, nhóm đề xuất các hướng mở rộng sau:

- Tích hợp mô hình vào ứng dụng web hoặc di động

- Sử dụng Flask, FastAPI hoặc Streamlit để triển khai mô hình inference online.
- Cho phép người dùng tải ảnh lá thật và nhận kết quả bệnh ngay lập tức.
- Tối ưu hóa mô hình cho thiết bị IoT/Edge
 - Chuyển đổi sang TensorRT, ONNX hoặc TFLite để chạy trên thiết bị nông nghiệp thông minh (ESP32-CAM, Jetson Nano, Raspberry Pi).
- Thử nghiệm thêm các mô hình tiên tiến hơn
 - Ví dụ: EfficientNetV2, ConvNeXt, Vision Transformer (ViT) hoặc Swin Transformer, nhằm tăng độ chính xác và khả năng khái quát hóa.
- Mở rộng dữ liệu thực tế tại Việt Nam
 - Xây dựng tập dữ liệu ảnh bệnh cây Việt hóa (các giống lúa, ngô, xoài, cà phê...) để phục vụ nghiên cứu ứng dụng AI trong nông nghiệp thông minh.
-

6.5. Kết luận cuối cùng

Hệ thống được xây dựng không chỉ có ý nghĩa học thuật mà còn có tiềm năng ứng dụng thực tế cao trong nông nghiệp thông minh (Smart Agriculture).

Việc kết hợp các mô hình hiện đại với quy trình xử lý dữ liệu chuyên sâu đã chứng minh AI có thể hỗ trợ nông dân phát hiện bệnh cây nhanh chóng, chính xác, và tiết kiệm chi phí.

7. Tài liệu tham khảo

1. New Plant Diseases Dataset (Augmented) – Kaggle.
2. PyTorch & TorchVision Documentation.
3. scikit-learn API: `compute_class_weight`, `confusion_matrix`.